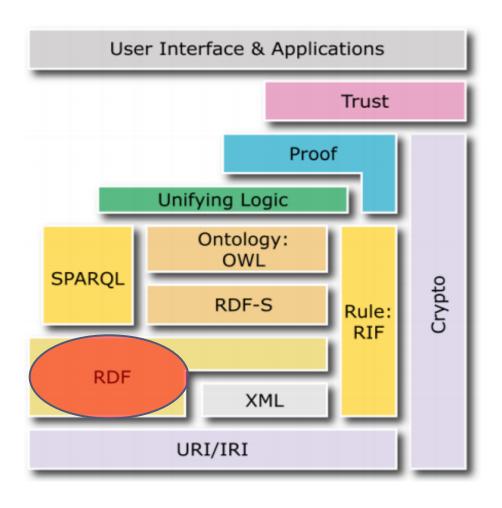
XML & Web Sémantique

Master IPS 2021/2022





Web sémantique Approche en couches





Chapitre 2 RDF: Modèle & Syntaxes

- I Introduction
- II Modèle de Données RDF
- III Sérialisation des graphes RDF

Syntaxe – RDF/XML

Syntaxe – Turtle



Introduction

Introduction

- RDF (Resource Description Framework) est la première brique des standards du web sémantique.
- Il recouvre à la fois **un modèle** et **plusieurs syntaxes** pour publier des données à propos de tout sur le web.
- Il permet de décrire tout type de ressources
- Tout portail d'information ou site à base de données peut utiliser le modèle RDF pour permettre à d'autres applications d'utiliser ses données.

ŧ

Introduction

Introduction

- RDF s'insère dans l'architecture classique du web.
- Il permet de:
 - Réutiliser le mécanisme des IRI (International Resource Identifier) pour identifier les ressources décrites,
 - Représenter et typer explicitement toute relation entre deux ressources.
- Utilisant et réutilisant les IRI:
 - n'importe quelle source de RDF peut dire n'importe quoi sur n'importe quel sujet;
 - n'importe quelle autre source peut ajouter quelque chose à ce qui a déjà été dit ;
 - ainsi de suite.

C'est l'architecture Web de Web Sémantique



Modèle de Données RDF Description de ressources

Description de ressources

- ▶ RDF : l'abréviation de « Resource Description Framework ».
- Il s'agit d'un cadre de description de ressources :
 - La Ressource est un concept de base sur le web sémantique :
 - □ Tout ce à quoi on peut se référer est considéré comme une ressource: une page web, une image, une vidéo, une personne, un lieu, un dispositif, un événement, une organisation, un produit ou un service.
 - □ Plus techniquement, tout ce qui peut être identifié par un IRI peut être considéré comme **une ressource**.
 - La Description d'une ressource est un ensemble d'attributs, de caractéristiques et de relations avec d'autres ressources.
 - Le Cadre standardise les modèles, langages et syntaxes de ces descriptions.



Modèle de Données RDF Description de ressources

Description de ressources

En bref

- Par RDF fournit une structure de données standard et un modèle pour encoder des données et des métadonnées sur n'importe quel sujet sur le web;
- Ces sujets sont appelés des ressources et identifiés par des IRI.



- ▶ Triplets : les atomes de connaissance en RDF
 - La plus petite structure de description en RDF est le triplet.
 - Ces triplets sont également appelés des déclarations ou des énoncés (statements).
 - Un triplet RDF **décrit** et **relie** une ressource en associant celle-ci à une propriété <u>et</u> à la valeur de cette propriété.
 - La structure de données de base de RDF est un triplet de la forme (sujet, prédicat, objet)
 - La **ressource** est le **sujet** de la déclaration,
 - la propriété est le prédicat,
 - la valeur de la propriété est l'objet de la déclaration.



▶ Triplets : les atomes de connaissance en RDF

Exemple:

- l'affirmation « Fabien a écrit une page websem.html à propos du web sémantique »
- peut être décomposée en deux triplets RDF ayant pour sujet le document websem.html :
 - □ (websem.html, auteur, Fabien)
 - □ (websem.html, thème, web sémantique)



▶ Triplets : les atomes de connaissance en RDF

- RDF identifie les ressources et les propriétés en utilisant des IRI.
- Les IRI pouvant aussi apparaître en valeur d'une propriété.
- Au lieu d'être des IRI, les objets des triplets RDF peuvent également être des littéraux,
 - Les **littéraux sont** des chaînes de caractères arbitraires typées ou non typées représentant des valeurs telles que du texte, des entiers, des dates, etc.

les triplets peuvent se combiner pour construire des graphes RDF.



- ▶ Triplets : les atomes de connaissance en RDF
 - Pour l'exemple du triplet (websem.html, auteur, Fabien)
 - le sujet est une page HTML sur le web,
 - la propriété est identifiée par un IRI unique au monde
 - l'objet du triplet peut être :
 - □ soit une ressource (un IRI qui représenterait Fabien),

On pourrait donc former le triplet suivant :

```
(<websem.html>, <author>, <Fabien>)
```

□ soit un littéral contenant le nom "Fabien".

Dans ce cas, on pourrait former le triplet suivant :

```
(<websem.html> <author> "Fabien")
```



- ▶ Triplets : les atomes de connaissance en RDF
 - Dans le premier cas : l'objet du triplet est une ressource

```
(<websem.html>, <author>, <Fabien>)
```

- Fabien> est une ressource et donc un nœud dans le graphe RDF
- ▶ Il pourrait être le sujet d'autres triplets
 - → l'IRI représentant ce sujet pourrait être déréférencée pour découvrir des faits supplémentaires sur « l'objet Fabien ».



▶ Triplets : les atomes de connaissance en RDF

Dans le deuxième cas : l'objet du triplet est un littéral

```
<websem.html> <author> "Fabien")
```

- l'objet est donné comme une chaîne
- ▶ Il devient une feuille dans le graphe RDF :
 - → le littéral "Fabien" est vu comme une valeur d'attribut et ne peut pas être le sujet de nouveaux triplets.



- Un modèle de données générique orienté graphes
 - Un triplet RDF peut aussi être vu comme un graphe décrivant et reliant les ressources.
 - Ce graphe comporte :
 - deux sommets ou deux nœuds
 - un arc ou arête entre ces deux sommets
 - RDF est un modèle de représentation de données décentralisées:



Il s'appuyant sur des triplets qui découpent et distribuent un graphe de description d'une envergure potentiellement mondiale.



Un modèle de données générique orienté graphes

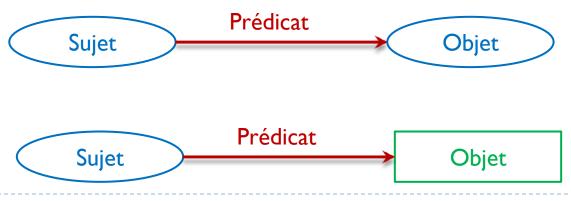
- Comme l'identification de ces ressources est basée sur des IRI,
 - si deux descriptions RDF ont chacune une ressource partageant le même IRI, ces deux ressources sont un seul et même nœud du graphe et les descriptions peuvent être jointes.
- Ce mécanisme extrêmement simple et puissant de représentation des données explique l'adoption de RDF dans une grande variété de domaines.



- Un modèle de données générique orienté graphes
 - Un graphe RDF est Un multi-graphe, orienté et étiqueté :
 - Multi-graphe, c'est-à-dire un graphe qui peut contenir plusieurs arcs et même des boucles entre deux mêmes sommets.
 - ▶ **Graphe orienté** : chaque arc est orienté, allant du sommet représentant le sujet au sommet représentant l'objet.
 - ▶ **Graphe étiqueté** : RDF attribue une étiquette à chaque arc et à chaque sommet du graphe.
 - □ Les arcs sont étiquetés avec des IRI identifiant le type de la relation décrite entre les deux sommets.
 - □ Les sommets sont étiquetés avec des IRI, des valeurs littérales ou des « identificateurs » de nœuds anonymes.



- Un modèle de données générique orienté graphes
 - Visuellement, la notation graphique associée à RDF est celle des graphes étiquetés où :
 - les nœuds des ressources sont représentés par des ellipses.
 - Les arcs orientés étiquetés sont représentés par des flèches avec un libellé
 - les littéraux sont représentés comme des nœuds rectangulaires contenant la valeur littérale.





- Un modèle de données générique orienté graphes
 - Exemple de description:

Assertions

```
« Le texte websem.html a pour auteurs Fabien, Olivier et Catherine, a pour sujet le web sémantique et a été écrit en 2011.»
```

Triplet

```
(websem.html , type , Text)
(websem.html , creator , Fabien)
(websem.html , creator , Olivier)
(websem.html , creator , Catherine)
(websem.html , subject , Semantic Web)
(websem.html , date , "2011")
```



Un modèle de données générique orienté graphes

Triplet

```
(websem.html , type , Text)
(websem.html , creator , Fabien)
(websem.html , creator , Olivier)
(websem.html , creator , Catherine)
(websem.html , subject , Semantic Web)
                                                        type
(websem.html , date , "2011")
                                                                   Text
                                                       creator
                                                                  Fabien
                                websem.html
                                                       creator
                                                                  Olivier
                                                       creator
                                                                 Catherine
                                                       subject
                                                                SemanticWeb
                                                        date
                                                             "2011"
```



Un modèle de données générique orienté graphes

- La structure de graphe de RDF est un **grand atout** pour un modèle de données ouvert sur le web :
 - Elle permet à RDF de proposer une structure très flexible et hautement extensible des données ;
 - n'importe qui peut ajouter un arc n'importe où dans le graphe chaque fois qu'il souhaite faire une nouvelle déclaration sur une nouvelle ressource ou une ressource déjà identifiée.
 - □ En réutilisant l'IRI d'une ressource existante pour identifier le sujet ou l'objet d'un nouveau triplet, la ressource est partagée entre les descriptions, et le graphe RDF s'étend naturellement.



▶ Espaces de noms pour l'identification des vocabulaires

- les IRI sont utilisés pour identifier des ressources dans toute leur diversité.
- Un cas particulier est celui de l'IRI utilisé pour identifier un ensemble de termes, un vocabulaire, un schéma.
- Dans ce cas, l'IRI est appelé un espace de noms, ou espace de nommage ou namespace.
- Les espaces de noms sont utilisés en particulier pour identifier les schémas déclarant les types de ressources et les types de relations utilisés pour étiqueter les graphes RDF.



▶ Espace de noms pour l'identification des vocabulaires

- Dans les documents XML, les espaces de nom sont associés à des préfixes, afin de raccourcir les identifiants localement en utilisant le préfixe au lieu de l'IRI complet.
- Par exemple, RDF fournit une primitive de **typage élémentaire** : **la relation type.**
- Cette relation permet de déclarer qu'une ressource appartient à une certaine classe, c'est-à-dire qu'elle est une **instance de cette classe**.
- Le prédicat type appartient au vocabulaire RDF qui est identifié par l'IRI http://www.w3.org/1999/02/22-rdf-syntax-ns#type et qui est souvent associé au préfixe rdf
- Par conséquent, le prédicat type peut être identifié par rdf: type au lieu de http://www.w3.org/1999/02/22-rdf-syntax-ns#type



- ▶ Espace de noms pour l'identification des vocabulaires
 - Quelques espaces de nom souvent utilisés dans WS:

Préfixe	URI de l'espace de nommage
rdf	http://www.w3.org/1999/02/22-rdf-syntax-ns#
rdfs	http://www.w3.org/2000/01/rdf-schema#
foaf	http://xmlns.com/foaf/0.1/ (un vocabulaire pour décrire les personnes)
dc	http://purl.org/dc/elements/1.1/ (métadonnées de documents)
dt	http://purl.org/dc/dcmitype/ (types de documents)
xsd	http://www.w3.org/2001/XMLSchema# (types élémentaires ex. dates)
data	http://ns.inria.fr/ex/data# (données d'exemples)



▶ Espace de noms pour l'identification des vocabulaires

En utilisant les espaces de nom, leurs préfixes, les IRI, les noms qualifiés et les littéraux, nous pouvons réécrire l'exemple précédent par :

Assertions

```
« Le texte websem.html a pour auteurs Fabien, Olivier et Catherine, a pour sujet le web sémantique et a été écrit en 2011. »
```

Triplets

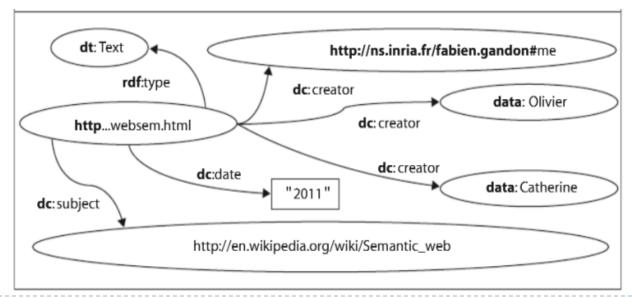


▶ Espace de noms pour l'identification des vocabulaires

Triplets

```
(http://ns.inria.fr/ex/websem.html , rdf:type , dt:Text)
(http://ns.inria.fr/ex/websem.html , dc:creator , http://ns.inria.fr/fabien.gandon#me)
(http://ns.inria.fr/ex/websem.html , dc:creator , #Olivier)
(http://ns.inria.fr/ex/websem.html , dc:creator , #Catherine)
(http://ns.inria.fr/ex/websem.html , dc:subject , http://en.wikipedia.org/wiki/Semantic_Web)
(http://ns.inria.fr/ex/websem.html , dc:date , "2011")
```

Graphe RDF





Multi-instanciation et typage orienté ontologies

- RDF, en utilisant la primitive **rdf**: **type**, permet de catégoriser une ressource en lui attachant **un** ou **plusieurs types**.
 - la ressource http://ns.inria.fr/ex/websem.html est déclarée comme étant un **Texte**, c'est-à-dire **une ressource de type** dt:Text ou une instance de la classe dt:Text.

```
(http://ns.inria.fr/ex/websem.html , rdf:type ,
dt:Text)
```

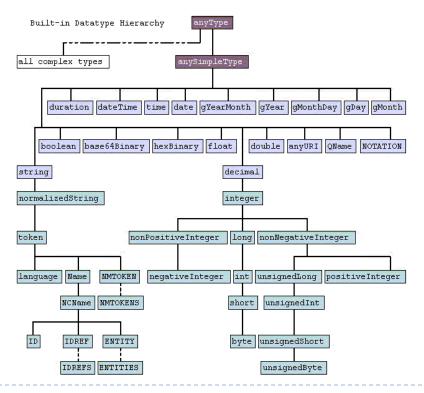


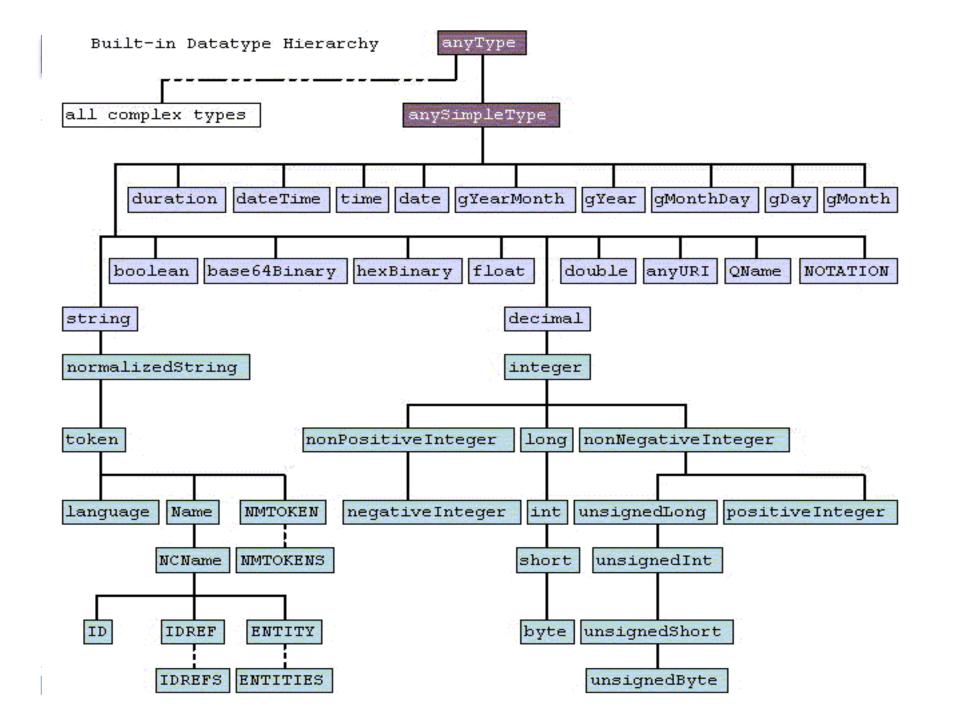
- Multi-instanciation et typage orienté ontologies
 - Une différence importante et très puissante entre le typage en RDF et le typage dans les langages de programmation orientés objets est qu'une ressource RDF peut appartenir à plusieurs classes complètement indépendantes
 - RDF autorise l'utilisation d'autant de types qu'on le souhaite pour une ressource
 - Il offre ainsi une sorte de **mécanisme de multi-instanciation**.



▶ 2.2.5 Multi-instanciation et typage orienté ontologies

Les littéraux, chaînes de caractères données en valeur d'une propriété, peuvent également **être typés** par les **types des schémas XML**.







▶ 2.2.5 Multi-instanciation et typage orienté ontologies

- Dans l'exemple suivant,
 - on a déclaré que la ressource http://ns.inria.fr/ex/websem.html appartenait aux deux classes dt:Text et foaf:Document
 - et que la date « 2011 » était du type xsd:gYear issu de la hiérarchie des types de XML Schema.

Triplets RDF

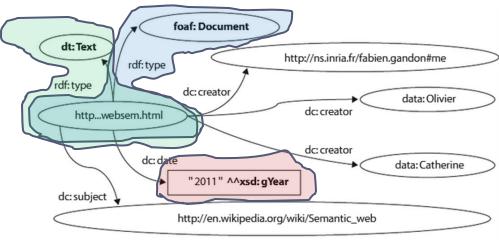
```
(http://ns.inria.fr/ex/websem.html , rdf:type , dt:Text)
(http://ns.inria.fr/ex/websem.html , rdf:type , foaf:Document)
...
(http://ns.inria.fr/ex/websem.html , dc:date , "2011"^^xsd:gYear)
```



▶ 2.2.5 Multi-instanciation et typage orienté ontologies

Triplets RDF

```
(http://ns.inria.fr/ex/websem.html , rdf:type , dt:Text)
(http://ns.inria.fr/ex/websem.html , rdf:type , foaf:Document)
(http://ns.inria.fr/ex/websem.html , dc:creator , http://ns.inria.fr/fabien.gandon#me)
(http://ns.inria.fr/ex/websem.html , dc:creator , #Olivier)
(http://ns.inria.fr/ex/websem.html , dc:creator , #Catherine)
(http://ns.inria.fr/ex/websem.html , dc:subject , http://en.wikipedia.org/wiki/Semantic_Web)
(http://ns.inria.fr/ex/websem.html , dc:date , "2011"^^xsd:gYear)
```





- Dans ce qui précède, les ressources ont toujours été associées à un IRI permettant de les identifier universellement.
- Dans certains cas, une telle identification unifiée des ressources n'est pas possible ou n'est pas souhaitable.
- Il peut être connu qu'un objet existe sans que l'on sache de quel objet exactement il s'agit.
- Par exemple, vous savez que chaque auteur de ce livre a une mère mais vous ne savez pas forcément identifier cette personne.



- Deux possibilités s'offrent en RDF :
 - On peut créer notre propre IRI ou réutiliser un IRI connu (options recommandées)
 - On peut utiliser le concept de **ressource anonyme**, aussi appelé **nœud vide (blank node** ou **bnode**).
- Avoir un nœud vide dans un graphe RDF signifie que le sommet représentant la ressource est inconnu ou anonyme,
 - c'est-à-dire que la ressource n'est pas identifiée par un IRI.



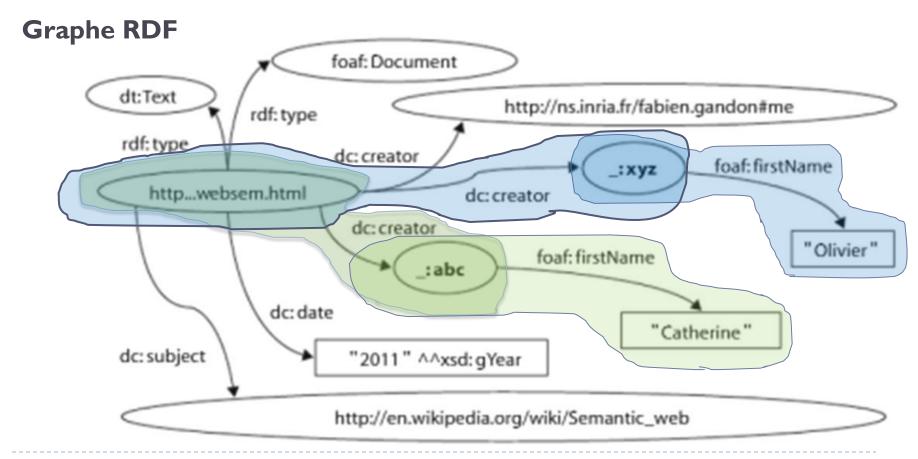
- Dans l'exemple suivant,
 - un nœud vide est utilisé pour représenter une personne
 - il est <u>localement</u> indiqué par un identifiant **composé d'un trait de soulignement** au lieu du préfixe de l'espace de nommage, ce qui donne _:xyz (Turtle).



Ressources anonymes

Triplets RDF







Ressources anonymes

- Un tel identificateur de ressource anonyme :
 - ne peut être considéré comme un nom unique au monde
 - ne peut être utilisé de façon non ambigüe qu'à l'intérieur du seul et même document RDF dans lequel cette ressource est déclarée.

Par conséquent :

les ressources anonymes déclarées dans différents documents, même si elles portent le même identifiant de bnode (ex.:_:xyz), désignent des ressources qui ne devraient pas être considérées comme étant les mêmes, sauf preuves supplémentaires.



Ressources anonymes

- En résumé, et d'un point de vue logique:
 - un nœud anonyme est comme une quantification existentielle :
 - il signifie qu'« il existe une ressource possédant telle et telle propriétés qui lui sont attribuées ».
- Si nous prenons l'exemple précédent, nous pourrions lire la partie décrivant le nœud anonyme _:xyz
 - comme « il existe une ressource qui a pour prénom (foaf) "Olivier" et qui est un auteur (dc) de la ressource « http://ns.inria.fr/ex/websem.html ».



Ressources anonymes

- Bien que les nœuds vides soient autorisés en RDF: ils sont fortement découragés dans la pratique, car ils cassent le graphe global, à l'exception de cas particuliers comme la déclaration d'une liste, d'une valeur structurée ou d'un conteneur.
- Ne pouvant pas être réutilisés en dehors du document RDF où elles ont été déclarées, les ressources anonymes empêchent quiconque d'étendre leur description et même de simplement s'y référer.



Ressources anonymes

- Dans l'exemple précédent,
 - chacun peut ajouter des informations sur Fabien simplement en réutilisant son IRI.
 - Cependant, dans ce même exemple, personne ne peut ajouter une information sur Olivier ou Catherine car il n'y a aucun moyen d'y faire référence en dehors du document RDF où ces ressources ont été déclarées.
- Cette situation s'oppose clairement aux principes d'extensibilité et de réutilisabilité qui sont à la base du web sémantique.



Plusieurs syntaxes pour un même modèle

Graphe RDF:

- les déclarations RDF reposent sur un modèle de multi-graphe orienté étiqueté,
- Il a l'avantage d'avoir la flexibilité et l'extensibilité nécessaires pour un monde de données ouvert.
- Il reste visuellement très compréhensible et intuitif.

Toutefois :

- le modèle des graphes RDF est un **modèle abstrait** qu'il faut doter d'une syntaxe concrète si l'on veut pouvoir le représenter en machine.
- Il y a plusieurs formats de sérialisation des graphes RDF :

□ RDF/XML	□ N-Triples	□ Turtle	□ N 3.



Plusieurs syntaxes pour un même modèle

RDF/XML

- Les documents RDF peuvent être écrits au format XML.
- Ce format est appelé **RDF/XML** et est conçu pour être lu par les machines et occasionnellement par les développeurs.
- Les graphes RDF sérialisés en arbres XML ne sont pas censés être affichés directement sur le web à des fins autres que le développement ou le débogage.
- En utilisant le langage XML, les documents RDF/XML peuvent être échangés entre des types très différents de systèmes et d'applications.



Plusieurs syntaxes pour un même modèle

N-Triples

- Possède une syntaxe plus simple.
- C'est un format texte brut qui sérialise un graphe RDF à raison d'un triplet par ligne du fichier texte et encodé uniquement en US-ASCII.
- conçu comme un sous-ensemble simplifié de N3 et Turtle, supportant un algorithme de parseur extrêmement simple et efficace.
- ne permet pas l'abréviation des IRI en utilisant les espaces de nommage et les préfixes.
- Chaque ligne, sauf commentaires et lignes blanches, se compose d'un triplet terminé par un point «.» avec, dans l'ordre d'apparence, le sujet, le prédicat et l'objet, séparés par des espaces.



Plusieurs syntaxes pour un même modèle

N-Triples

- Ce format est notamment approprié pour des applications produisant ou consommant des flux de données
- son principe le rend très gourmand en taille par rapport aux autres formats, notamment en raison de l'énorme place prise par les espaces de nommage dans les IRI des triplets.
- n'est pas efficace en termes de taux de compression des données
- très simple et rapide à lire et écrire par programme.



Plusieurs syntaxes pour un même modèle

Turtle

- Turtle (Terse RDF Triple Language) est un format textuel compact pour sérialiser un graphe RDF de façon moins verbeuse que N-Triples, mais plus simple que N3.
- En Turtle, nous ne sommes plus restreints à un triplet par ligne, le document se compose d'une séquence de directives, déclarations de triplets et lignes vides.
- En Turtle inclus les directives la déclaration des préfixes d'espaces de nommage. Grâce à ces déclarations, les IRIs des triplets peuvent être abrégés efficacement



Modèle de Données RDF

Exercices



II - Modèle de Données RDF Graphes

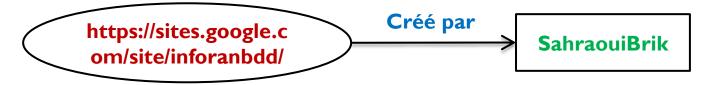
Exercice 1:

Représenter cette phrase sous forme de **Triplet RDF** et **Graphe RDF** : «SahraouiBrik est le créateur de la ressource https://sites.google.com/site/inforanbdd/»

- Cette phrase est composée des parties suivantes :
 - Sujet (ressource) https://sites.google.com/site/inforanbdd/
 - Prédicat (propriété) Créé par
 - Objet (littéral) "SahraouiBrik"
- Tripler RDF:

(https://sites.google.com/site/inforanbdd/, Créé par , SahraouiBrik)

Graphe RDF:





II - Modèle de Données RDF Graphes - Exercices

Exercice 2:

« La personne référencée par l'IRI http://www.w3.org/stafID/85740 est appelée Ora Lassila et a pour adresse Email lassila@w3.org. La ressource http://www.w3.org/Home/Lassila a été créée par cette personne ».

Les Triplets RDF

```
(http://www.w3.org/stafID/85740, à pour Nom, Ora Lassila)
(http://www.w3.org/stafID/85740, à pour Email, lassila@w3.org)
(http://www.w3.org/Home/Lassila, Créateur de, http://www.w3.org/stafID/85740)
```

Le Graphe RDF :

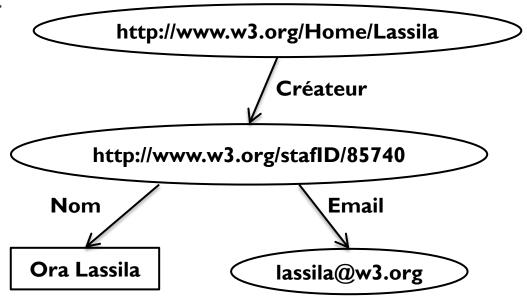


II - Modèle de Données RDF Graphes - Exercices

Les Triplets RDF

```
(http://www.w3.org/staflD/85740, Nom, Ora Lassila)
(http://www.w3.org/staflD/85740, Email, lassila@w3.org)
(http://www.w3.org/Home/Lassila, Créateur, http://www.w3.org/staflD/85740)
```

Le Graphe RDF :





II - Modèle de Données RDF

Exercices

Exercice 3:

- Soit la phrase en langage naturel suivante:
 « la Faculté des Sciences de rabat est située à un emplacement qui a comme numéro 4 est comme avenue Ibn Battouta et comme code postale 10000 avec comme ville Rabat et comme pays Maroc »
 - 1. Exprimer ces phrases sous forme de triples RDF avec au moins un nœud vide.
 - 2. Tracer ensuite le graphe RDF Correspondant

Remarque:

- Identifier le nœud vide par _:X1
- Utiliser ex comme préfixe pour chaque propriété (exemple ex:situé_à)
- la Faculté des Sciences de rabat est identifié par "loca:faculté-des-sciences-de-rabat "



II - Modèle de Données RDF

Exercices

Exercice 3

Soit la phrase en langage naturel suivante:

"la Faculté des Sciences de rabat est situé à *un emplacement* qui a comme numéro 4 est comme avenue Ibn Battouta et comme code postal 10000 avec comme ville Rabat et comme pays Maroc"

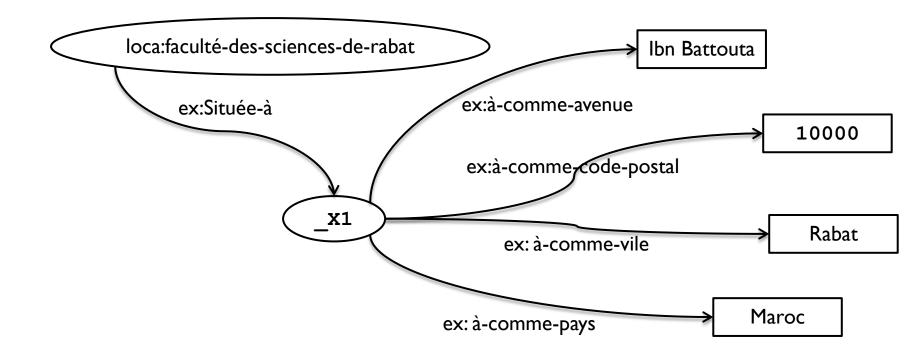
1. Exprimer cette phrases sous de triples RDF avec au moins un nœud vide.



II - Modèle de Données RDF Exercices

Exercice 3

2. Tracer ensuite le graphe RDF Correspondant





Chapitre 3 RDF & Syntaxes RDF

- I Introduction
- II Modèle de Données RDF
- III Sérialisation des graphes RDF

Syntaxe - RDF/XML

Syntaxe – Turtle